

基于 RoBERTa 与多维独立分类头的文本 MBTI 人格预测与可解释性分析

吴俊达 王琦锋 陈明阳 刘毅恒

计算机科学与技术学院

2026 年 6 月 10 日

① 项目背景

② 数据集

③ 模型设计

④ 实验结果

⑤ 总结

项目简介

项目简称: **MBTI Personality Prediction**

目标: 根据用户发布的英文论坛文本, 预测其 MBTI 性格类型。

任务定义

输入:

用户历史帖子文本

输出:

MBTI 四个维度 (E/I, S/N, T/F, J/P)


最终组合得到 16 种 MBTI 类型

数据规模: 106,067 条样本

模型: RoBERTa-base + Multi-Task Classification

最终 Exact Match: 86.0%

数据集介绍



数据来源:

PersonalityCafe 论坛用户匿名帖子

Kaggle 公开数据集





样本数 106,067

MBTI 类别 16 类

平均文本长度 3255 字符

最大长度 13180 字符

MBTI 4-Dimension Label Distribution




特点:


论坛语言风格明显

类别严重不均衡

基本都是长文本任务

Text Length Distribution





四维之间相关性较弱

分类策略

选中：

$(E/I, S/N, T/F, J/P)$

四个二分类。

这样设计的原因

- a 每个分类器都能利用全部 106k 样本
- b 可解释性更强
- c 可以针对单个维度处理类别不平衡
- d 训练稳定性优于 16 分类

数据预处理


主要步骤:

- a URL 清理
- b HTML 标签清理
- c @Mention 清理
- d 帖子分隔符清理
- e 空白字符规范化


标签转换:

$$INTP \rightarrow (EI, SN, TF, JP) = (1, 1, 0, 1)$$

Train/Test Split



Stratified Split Verification




数据划分:

Train: 84,853

Test: 21,214

Stratified Split

模型整体架构



RoBERTa 编码器

采用：

FacebookAI/roberta-base

12 层 Transformer

768 维隐藏层

125M 参数

设计选择：

CLS Pooling

max_length=512

全参数微调 (Fine-tuning)

原因：

英文预训练效果成熟

长文本适配良好

实验验证优于 Mean Pooling

训练配置

Optimizer	AdamW
Encoder LR	2.84e-5
Classifier LR	1e-4
Batch Size	32
Max Length	512
FP16	True
Epochs	10

额外策略:

Cosine Learning Rate

Warmup

Gradient Clipping

Mixed Precision Training

类别不平衡处理

问题:

S 类仅占 8.7%

I 类占 76.1%

解决方案:

BCEWithLogitsLoss

pos_weight

提高 SN 维度损失权重

总损失:

$$L = 0.25L_{EI} + 0.35L_{SN} + 0.20L_{TF} + 0.20L_{JP}$$

超参数搜索

采用：

Optuna

Random Search

两阶段搜索：

a 离散参数

Pooling

Head Hidden Size

b 连续参数

Learning Rate

Dropout

Weight Decay


Warmup

总计 18 次 Trial。

参数池

TRIAL	PHASE	POOLING	HEAD	DROPOUT	ENC LR	CLS LR	WD	WARMUP	MEAN ACC	EXACT	F1	AUC
1	phase1	mean	64	0.200	2.0e-5	1.0e-4	1.0e-2	0.10	92.21%	77.6%	90.10%	96.54%
2	phase1	mean	64	0.200	2.0e-5	1.0e-4	1.0e-2	0.10	92.59%	79.3%	90.48%	96.44%
3	phase1	mean	512	0.200	2.0e-5	1.0e-4	1.0e-2	0.10	92.73%	79.7%	90.51%	96.88%
4	phase1	cls	512	0.200	2.0e-5	1.0e-4	1.0e-2	0.10	93.15%	80.9%	91.12%	97.17%
5	phase1	cls	64	0.200	2.0e-5	1.0e-4	1.0e-2	0.10	92.67%	78.7%	90.66%	96.75%
6	phase1	mean	256	0.200	2.0e-5	1.0e-4	1.0e-2	0.10	92.76%	79.6%	90.50%	96.82%
7	phase1	cls	256	0.200	2.0e-5	1.0e-4	1.0e-2	0.10	92.42%	78.0%	90.20%	96.54%
8	phase1	cls	64	0.200	2.0e-5	1.0e-4	1.0e-2	0.10	93.13%	80.4%	90.98%	97.02%
9	phase1	mean	128	0.200	2.0e-5	1.0e-4	1.0e-2	0.10	92.35%	78.3%	90.06%	96.83%
10	phase2	cls	512	0.212	2.7e-5	1.9e-4	2.5e-4	0.02	93.69%	82.4%	91.79%	97.58%
11	phase2	cls	512	0.147	5.5e-6	2.4e-4	2.5e-4	0.11	92.73%	79.1%	90.65%	97.07%
★ 12	phase2	cls	512	0.106	2.8e-5	2.2e-4	7.1e-6	0.03	93.84%	82.4%	92.18%	97.66%
13	phase2	cls	512	0.155	8.6e-6	1.3e-4	5.3e-5	0.04	93.35%	81.0%	91.34%	97.41%
14	phase2	cls	512	0.284	6.4e-6	8.4e-5	2.9e-5	0.07	93.08%	80.0%	91.15%	97.06%
15	phase2	cls	512	0.336	7.2e-6	1.3e-4	2.3e-4	0.01	93.13%	80.2%	91.11%	97.16%
16	phase2	cls	512	0.282	6.8e-6	5.6e-5	6.2e-3	0.14	92.48%	77.7%	90.28%	96.73%
17	phase2	cls	512	0.343	8.6e-6	6.0e-5	5.5e-4	0.07	93.08%	80.1%	91.10%	97.17%
18	phase2	cls	512	0.137	1.2e-5	5.3e-5	4.3e-3	0.04	93.37%	81.0%	91.43%	97.44%
19	phase2	cls	512	0.299	8.7e-6	1.3e-4	1.5e-4	0.03	93.22%	80.5%	91.30%	97.18%

超参数搜索结果



阶段一最佳:

CLS Pooling

Hidden Size=512

阶段二最佳:

Encoder LR = $2.84e-5$

Warmup = 0.027

重要发现

子集搜索得到的全局参数不一定直接适用于全量训练，尤其是连续参数
因此最终采用：

离散参数采用最优解

连续参数适当回退

最终参数：

Optimizer	AdamW
Encoder LR	2.84e-5
Classifier LR	1e-4
Batch Size	32
Max Length	512
FP16	True
Epochs	10

最终实验结果

指标	数值
Exact Match	86.0%
Mean Accuracy	95.1%
Mean F1	93.7%
Mean AUC	98.0%
Macro MCC	0.854


最佳维度:

SN F1 = 0.989

最困难维度:





EI F1 = 0.885

ROC 曲线分析



四个维度 AUC 均接近 1
模型具有较强区分能力
TF 维度表现最好

混淆矩阵分析




EI 和 JP 错误相对较多

SN 维度分类几乎完全正确

错误主要来自相邻人格倾向

模型输出分析


MBTI 4-Dimension Radar



综合展示四个维度性能。

模型输出分析

Confidence Distribution — Correct vs Wrong



模型预测置信度分布。

与 Baseline 比较

指标	Baseline	最终模型
Overall Acc	80.6%	86.0%
Mean Acc	93.2%	95.1%
Mean F1	91.3%	93.7%

提升:

Overall Accuracy +5.4pp

Mean F1 +2.4pp

说明:

超参数搜索有效

CLS Pooling 贡献明显

长文本输入十分重要

开发过程中的关键问题

问题	解决方案
FP16 下 BCELoss 崩溃	Loss 改为 FP32 计算
学习率错误	检查配置文件数值类型
搜索结果失效	参数回退策略
Batch 过大训练慢	128 降至 32

总结与未来工作

项目成果

完成 106k 样本 MBTI 预测系统

实现 RoBERTa 多任务分类架构

完成超参数自动搜索

Exact Match 达到 86.0%

未来方向

RoBERTa-large

Focal Loss

更严格的用户级划分

更强的可解释性分析模块

Thanks!